

# Low-quality Motion Deblurring from a Single Image

Eduardo Stuani  
Gustavo Prolla Lacroix

January 2024

## 1 Introdução

Borramento causado por movimento da câmera é um dos artefatos mais comuns na fotografia. Seja porque não há luz o suficiente para usar uma velocidade do obturador maior, seja porque tomamos muito café no dia, diversas vezes tiramos uma foto e o resultado é desapontante.

Restaurando uma imagem não borrada a partir de uma única fotografia borrada é um problema fundamental na área de imagens digitais. Se assumirmos que o kernel do borramento é *shift-invariant* – isto é, a imagem pode ser transladada e o borramento que ele causa continuará o mesmo – o problema reduz à deconvolução. Mais especificamente, se assumirmos que o kernel é conhecido trata-se de deconvolução não-cega. Caso contrário, trata-se de deconvolução cega, em que é preciso estimar o kernel do borramento e a imagem latente – um problema bem mais difícil.

## 2 Solução Proposta

Métodos de deconvolução atuais têm um bom desempenho quando a imagem borrada não contém ruído e o kernel de borramento não contém erro. Com isso, tem-se a ideia de que um modelo melhor do ruído e um manejo explícito dos artefatos gerados a partir de erros na estimação do kernel deve melhorar significativamente o resultado da deconvolução.

Três contribuições são propostas pelo autores [SJA08]. A primeira é um novo modelo do ruído, em que sua distribuição é *especialmente* randômica. Isso auxilia na distinção dos erros da estimação do ruído dos erros da estimação do kernel. A segunda é uma restrição na suavidade da imagem latente que é imposta onde a imagem observada possui baixo contraste. Isso auxilia a reduzir ruído periódico tanto nas regiões suaves quanto nas regiões texturizadas próximas. A terceira é um algoritmo eficiente de otimização. O algoritmo consiste em iniciar com uma estimativa do kernel imprecisa – por exemplo, uma linha reta ou pontos espalhados – e iterativamente estimar a imagem latente e o kernel de borramento.

### 2.1 Modelo Probabilístico

O modelo proposto unifica deconvolução cega e não-cega em um único problema de máximo a posteriori (MAP). Podemos modelar o borramento de uma imagem como o processo de convolução

$$I = L \circledast f + n$$

onde  $I$  é a imagem observada,  $L$  é a imagem latente não-borrada,  $f$  é o kernel do borramento e  $n$  é o ruído aditivo. Pelo teorema de Bayes, temos que

$$p(L, f|I) \propto p(I|L, f)p(L)p(f) \quad (1)$$

onde  $p(I|L, f)$  é a função de verossimilhança, e  $p(L)$  e  $p(f)$  são as probabilidades a priori da imagem latente e do kernel do borramento.

**Verossimilhança**  $p(I|L, f)$ . A verossimilhança de uma imagem observada dada a imagem latente e o kernel de borramento é baseada no modelo de convolução  $n = L \circledast f - I$ . O ruído da imagem  $n$  é modelado como um conjunto de variáveis aleatórias independentes e identicamente distribuídas, cada uma seguindo uma distribuição Gaussiana.

Nessa formulação, modelamos a aleatoriedade espacial do ruído restringindo várias ordens de sua derivada. Escrevemos as derivadas parciais de  $n$  nas duas direções como  $\partial_x n$  e  $\partial_y n$ , e as computamos utilizando diferença anterior. Como cada  $n$  é uma variável aleatória independente e identicamente distribuída seguindo uma distribuição Gaussiana com desvio padrão  $\zeta_0$ , é provado por [Sim02] que as derivadas parciais também seguem distribuições Gaussianas  $N(\partial_x n_i|0, \zeta_1)$  e  $N(\partial_y n_i|0, \zeta_1)$  com desvio padrão  $\zeta_1 = \sqrt{2} \cdot \zeta_0$ .

Na seguinte formulação, utilizamos  $\partial^*$  para representar o operador de qualquer derivada parcial e  $\kappa(\partial^*)$  para representar a sua ordem.

$$\begin{aligned} p(I|L, f) &= \prod_{\partial^* \in \Theta} \prod_i N(\partial^* n_i | 0, \zeta_{\kappa \partial^*}) \\ &= \prod_{\partial^* \in \Theta} \prod_i N(\partial^* I_i | \partial^* I_i^c, \zeta_{\kappa \partial^*}) \end{aligned} \quad (2)$$

onde  $I_i \in I$  é o valor do pixel,  $I_i^c$  é o pixel com coordenada  $i$  na imagem reconvolucionada  $I^c = L \otimes f$ , e  $\Theta$  é o conjunto de todos os operadores de derivadas parciais que utilizamos,  $\Theta = \{\partial_0, \partial_x, \partial_y, \partial_{xx}, \partial_{xy}, \partial_{yy}\}$ .

**Prior  $p(f)$ .** Modelamos os valores do kernel do borramento seguindo uma distribuição exponencial. O kernel normalmente identifica o caminho percorrido pela câmera ao tirar a foto, portanto possui muitos valores próximos de zero.

$$p(f) = \prod_j e^{-\tau f_j}, f_j \geq 0$$

Onde  $j$  indexa os elementos do kernel.

**Prior  $p(L)$ .** Construimos  $p(L)$  com duas partes: o prior local e o prior global. O objetivo disso é ter um termo que reduz tanto a dificuldade do problema no geral quanto a introdução de ruído periódico.

$$p(L) = p_g(L) p_l(L)$$

**Prior Global  $p_g(L)$ .** Pesquisas sobre a estatística de imagens naturais mostram que gradientes de imagens naturais seguem uma distribuição com caudas pesadas [RB05; WF07]. Representamos essa distribuição através de uma função definida por partes

$$\Phi(x) = \begin{cases} -k|x| & x \leq l_t \\ -(ax^2 + b) & x > l_t \end{cases} \quad (3)$$

Setamos  $k = 2.7$ ,  $l_t = 6.1 \cdot 10^{-4}$ ,  $a = 6.1 \cdot 10^{-4}$ ,  $b = 5.0$ . Tendo modelado a densidade logarítmica dos gradientes, a definição do prior global é escrita como

$$p_g(L) \propto \prod_i e^{\Phi(\partial L_i)}$$

**Prior Local  $p_l(L)$ .** Utilizamos a imagem borrada para restringir os gradientes da imagem latente de forma a reduzir a introdução de ruído periódico. Borramento por movimento pode ser considerado um processo de suavização. Em uma região localmente suave da imagem borrada – com pixels quase da mesma cor –, a região desborrada correspondente deve também ser suave.

Para formular o prior local, para cada pixel  $i$  na imagem borrada  $I$ , calculamos o desvio padrão de uma janela de mesmo tamanho que o kernel do borramento centrada nesse pixel. Se o desvio padrão for menor que um certo limiar  $t$ , determinamos que esse pixel  $i$  pertence à região  $\Omega$ .




Figure 1: Cálculo da região  $\Omega$  utilizando  $t = 5$

Para todos os pixels em  $\Omega$ , restringimos o gradiente da imagem desburrada a ser similar ao da imagem borrada. Definimos que os erros seguem uma distribuição Gaussiana de média zero e desvio padrão  $\sigma_1$

$$p_l(L) = \prod_{i \in \Omega} N(\partial_x L_i - \partial_x I_i | 0, \sigma_1) N(\partial_y L_i - \partial_y I_i | 0, \sigma_1)$$

## 2.2 Otimização

O problema de encontrar o máximo a posteriori (MAP) é transformado em um problema de minimização de energia, que minimiza o logaritmo negativo da probabilidade que definimos,  $E(L, f) \propto -\log(p(L, f|I))$ . A partir das definições acima obtém-se o seguinte

$$\begin{aligned} E(L, f) \propto & \left( \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \|\partial^* L \otimes f - \partial^* I\|_2^2 \right) \\ & + \lambda_1 \|\Phi(\partial_x L) + \Phi(\partial_y L)\|_1 \\ & + \lambda_2 (\|\partial_x L - \partial_x I\|_2^2 \circ M + \|\partial_y L - \partial_y I\|_2^2 \circ M) + \|f\|_1 \end{aligned} \quad (4)$$

Onde  $\|\cdot\|_p$  é o operador de norma- $p$  e  $\odot$  é o operador de multiplicação ponto a ponto. Os quatro termos de (4) correspondem aos termos em (1) na mesma ordem.  $M$  é uma máscara binária que codifica  $p_l(L)$ . Para qualquer elemento  $m_i \in M$ ,  $m_i = 1$  se o pixel correspondente  $I_i \in \Omega$ . Os parâmetros  $w_{\kappa(\partial^*)}$ ,  $\lambda_1$  e  $\lambda_2$  dos termos de probabilidade:

$$w_{\kappa(\partial^*)} = \frac{1}{\zeta_{\kappa(\partial^*)}^2 \tau}, \quad \lambda_1 = \frac{1}{\tau}, \quad \lambda_2 = \frac{1}{\sigma_1^2 \tau}$$

Para estimar  $L$  e  $f$ , portanto, primeiro minimizamos a energia de  $L$ ,  $E_L$ , mantendo  $f$  fixo, e depois minimizamos a energia de  $f$ ,  $E(f)$ , mantendo  $L$  fixo. Isso permite a aplicação de alguns teoremas para que esse cálculo de minimização seja eficiente. A necessidade de um novo método de otimização vem do fato de que tentar minimizar (4) pelo método do gradiente é extremamente lento e não converge bem.

### 2.2.1 Otimização de $L$

Aqui, mantemos  $f$  fixo e otimizamos  $L$ . A energia  $E$  de (4) pode ser simplificada para  $E_L$  removendo os termos de valor constante.

$$\begin{aligned} E_L = & \left( \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \|\partial^* L \otimes f - \partial^* I\|_2^2 \right) \\ & + \lambda_1 \|\Phi(\partial_x L) + \Phi(\partial_y L)\|_1 \\ & + \lambda_2 (\|\partial_x L - \partial_x I\|_2^2 \circ M + \|\partial_y L - \partial_y I\|_2^2 \circ M) \end{aligned} \quad (5)$$

Mesmo simplificada,  $E_L$  ainda é difícil de ser otimizada. Os autores propõem uma mudança de variável e uma técnica de rebalanceamento de parâmetros iterativa. A intenção é separar as convoluções dos outros termos em (5) para que possam ser computadas rapidamente utilizando a transformada de Fourier.

O método consiste em introduzir um par de variáveis auxiliares  $\Psi = (\Psi_x, \Psi_y)$  para  $\partial L = (\partial_x L, \partial_y L)$ , com a condição de que  $\Psi \approx \partial L$ . Portanto, para cada  $(\partial_x L_i, \partial_y L_i) \in \partial L$  existe  $(\psi_{x,i}, \psi_{y,i}) \in \Psi$ . Transformamos a equação (5) em

$$\begin{aligned} E_L = & \left( \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \|\partial^* L \otimes f - \partial^* I\|_2^2 \right) \\ & + \lambda_1 \|\Phi(\Psi_x) + \Phi(\Psi_y)\|_1 \\ & + \lambda_2 (\|\Psi_x - \partial_x I\|_2^2 \circ M + \|\Psi_y - \partial_y I\|_2^2 \circ M) \\ & + \gamma (\|\Psi_x - \partial_x L\|_2^2 + \|\Psi_y - \partial_y L\|_2^2) \end{aligned} \quad (6)$$

onde  $\gamma$  é um peso que é iterativamente aumentado, de modo que a condição  $\Psi = \partial L$  seja eventualmente alcançada. Setamos  $\gamma = 2$  e a cada iteração seu valor é dobrado.

**Atualização de  $\Psi$ .** Com  $L$  e  $\partial^* L$  fixo, precisamos minimizar

$$\begin{aligned} E'_\Psi = & \lambda_1 \|\Phi(\Psi_x) + \Phi(\Psi_y)\|_1 + \lambda_2 (\|\Psi_x - \partial_x I\|_2^2 \circ M \\ & + \|\Psi_y - \partial_y I\|_2^2 \circ M + \gamma \|\Psi_x - \partial_x L\|_2^2 + \gamma \|\Psi_y - \partial_y L\|_2^2) \end{aligned} \quad (7)$$

Podemos decompor  $\Psi$  em todos seus elementos  $\psi_{i,x}$  e  $\psi_{i,y}$  de forma que a equação se torna uma soma de sub-energias,  $E'_\Psi = \sum_i (E'_{\psi_{i,x}} + E'_{\psi_{i,y}})$ , onde cada  $E'_{\psi_{i,v}}$ ,  $v \in \{x, y\}$ , contém apenas uma variável  $\psi_{i,v} \in \Psi_v$ . Temos então que

$$E'_{\psi_{i,v}} = \lambda_1 |\Phi(\psi_{i,v})| + \lambda_2 m_i (\psi_{i,v} - \partial_v I_i)^2 + \gamma (\psi_{i,v} - \partial_v L_i)^2 \quad (8)$$

Como  $\Phi(x)$  é função definida por partes, cujo maior grau é dois, e os outros dois termos também são quadráticos,  $E'_{\psi_{i,v}}$  tem valor mínimo quando sua derivada é zero. Portanto, calculamos esse valor para cada uma das partes de  $\Phi(x)$  e escolhemos o menor que respeite o limite da concatenação  $l_t$ . Assim rapidamente obtemos um mínimo global para  $\Psi$ .

**Atualização de  $L$ .** Com  $\Psi$  fixo precisamos minimizar

$$E'_L = \left( \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \|\partial^* L \otimes f - \partial^* I\|_2^2 \right) + \gamma \|\Psi_x - \partial_x L\|_2^2 + \gamma \|\Psi_y - \partial_y L\|_2^2 \quad (9)$$

Como os principais termos de  $E'_L$  envolvem convolução, iremos operar no domínio frequência. Aplicando a transformada de Fourier e utilizando o teorema de Plancherel [Bra99], chegamos que o valor de  $L$  que minimiza  $E'_L$  é

$$L^* = \mathcal{F}^{-1} \left( \frac{\overline{\mathcal{F}(f)} \circ \mathcal{F}(I) \circ \Delta + \gamma \overline{\mathcal{F}(\partial_x)} \circ \mathcal{F}(\Psi_x) + \gamma \overline{\mathcal{F}(\partial_y)} \circ \mathcal{F}(\Psi_y)}{\overline{\mathcal{F}(f)} \circ \mathcal{F}(f) \circ \Delta + \gamma \overline{\mathcal{F}(\partial_x)} \circ \mathcal{F}(\partial_x) + \gamma \overline{\mathcal{F}(\partial_y)} \circ \mathcal{F}(\partial_y)} \right) \quad (10)$$

onde  $\Delta = \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \overline{\mathcal{F}(\partial^*)} \circ \mathcal{F}(\partial^*)$  e  $\overline{(\cdot)}$  representa o operador do conjugado. A divisão é feita ponto a ponto.

### 2.2.2 Otimização de $f$

Para parte de otimizar o kernel, mantemos  $L$  fixo e atualizamos  $f$ . A energia de  $f$ ,  $E(f)$ , pode ser obtida de (4)

$$E(f) = \left( \sum_{\partial^* \in \Theta} w_{\kappa(\partial^*)} \|\partial^* L \otimes f - \partial^* I\|_2^2 \right) + \|f\|_1 \quad (11)$$

O termo da convolução é quadrático com respeito a  $f$ . Dessa forma, podemos escrever (11) como uma multiplicação de matrizes, similarmente como foi feito em [Ara+20]. Além disso, removendo o somatório aplicando os operadores de  $\Theta$  na multiplicação de  $w_{\kappa(\partial^*)}$  com a respectiva derivada parcial  $\partial^*$  e a imagem em questão (latente  $L$  e degradada  $I$ ), temos

$$E(f) = \|Af - B\|_2^2 + \|f\|_1 \quad (12)$$

Onde  $A$  é uma matriz de Toeplitz duplamente bloqueada, a qual é constituída pelos elementos que dependem da imagem latente  $L$ ,  $f$  é o kernel que desejamos estimar e  $B$  é uma matriz na qual os elementos dependem da imagem degradada  $I$ . Realizando essa simplificação, a equação (12) pode ser resolvida pela abordagem de [KKB07], a qual minimiza a energia transformando essa otimização em um problema dual e o resolve utilizando o método de ponto interior de Newton. Dessa forma, são obtidos resultados bem próximos do mínimo global.

## 3 Implementação

Separamos o Algoritmo 1 em 4 funções: calcular o prior local, calcular  $\Psi$ , calcular  $L$ , e calcular  $f$ . As funções funcionam para matrizes 2D, portanto para imagens coloridas, passamos cada canal separadamente. Teoricamente, implementamos o que estava no artigo original, todavia temos dois problemas.

A otimização de  $L$  (Seção 2.2.1) não converge. Veja os critérios de parada no algoritmo do artigo original (Algoritmo 1). Entendemos  $\Delta L$  como sendo a diferença dos valores calculados de  $L$  entre uma iteração e outra. Esse valor costuma ser maior que 1 não importa qual iteração (quase sempre  $\Delta L > 500$ ). Nas primeiras iterações  $L$  parece ficar mais nítida, porém depois acaba voltando a borrar, eventualmente se tornando uma imagem de cor única. Se não limitarmos o número de iterações, o laço interno no Algoritmo 1 roda 63 vezes, quando  $\gamma$  causa um *integer overflow*.

O método de otimização de  $f$  (Seção 2.2.2) no artigo original transforma o problema da equação (12) em um problema dual para então aplicar o método de ponto interior de Newton para resolvê-lo. Tentamos implementar essa transformação do zero e até mesmo utilizar métodos prontos de otimização da biblioteca Scipy, porém não obtivemos resultados satisfatórios. Dessa forma, o caminho que seguimos para resolver a equação (12) foi utilizar o método `lsq_linear()` do Scipy. A função resolve este seguinte problema:

$$\begin{aligned} &\text{minimizar} && 0.5 \cdot \|Af - b\|^2 \\ &\text{sujeito a} && lb \leq f \leq ub \end{aligned} \quad (13)$$

Onde  $A$  é a matriz de Toeplitz,  $f$  é o kernel,  $b$  é um vetor proveniente do  $B$  original da equação (12),  $lb$  é o limite inferior (o qual setamos como 0) e  $ub$  é o limite superior (o qual setamos como mais infinito). Entendemos que esta abordagem não é a mais correta porém era a solução que encontramos no momento. Como resultado desta alteração, conseguimos obter apenas uma estimativa aproximada do kernel, não a melhor. Além disso, também é importante mencionar, que temos um parâmetro  $n\_rows$  o qual manipula o tamanho que será extraído para construção da matriz  $A$ . Isso ocorre porque não é possível manter em memória toda matriz  $A$  se ela fosse computada a partir de todos os pixels da imagem. Consequentemente também são selecionados os pixels correspondentes para construir o vetor  $b$ .

Assim, o algoritmo proposto é descrito por:

---

**Algorithm 1** Image Deblurring algorithm proposed in the original paper

---

**Require:** The blurred image  $I$  and a kernel estimate

Compute smooth region  $\Omega$  with  $t = 5$ .

$L \leftarrow I$

**repeat**

**repeat**

        Update  $\Psi$  according to (7)

        Compute  $L$  according to (10)

**until**  $\|\Delta L\|_2 < 1 \cdot 10^{-5}$  e  $\|\Delta \Psi\|_2 < 1 \cdot 10^{-5}$

        Update  $f$  according to (12)

**until**  $\|\Delta f\|_2 < 1 \cdot 10^{-5}$

---

## 4 Resultados

Como diz no título desse trabalho, os resultados são de baixa qualidade. Isso se deve a dois principais motivos. Primeiro, o fato de nem  $L$  nem  $f$  convergir com a nossa implementação. Segundo, não estamos fazendo nenhum tipo de tratamento de borda, algo que em métodos que utilizam a transformada de Fourier é fundamental. Além disso, os autores do paper original realizam vários ajustes pós-processamento, que nós não repetimos.

### 4.1 Deconvolução Não-cega

Para as figuras 2, 3 e 4, fizemos a convolução da imagem original com o kernel e somamos ruído gaussiano. Para gerar a imagem desborrada seguimos o seguinte algoritmo:

---

**Algorithm 2** Nonblind Deconvolution

---

**Require:** The blurred image  $I$  and kernel  $f$

Compute smooth region  $\Omega$  with  $t = 5$ .

$L \leftarrow I$

$i \leftarrow 0$

**while**  $i < 5$  **do**

    Update  $\Psi$  according to (7)

    Compute  $L$  according to (10)

$i \leftarrow i + 1$


**end while**

Choose the best looking image

---



(a) Desborrada



(b) Borrada



(c) Original

Figure 2: Esquilo fofinho é borrado por kernel malvado.



(a) Desborrada



(b) Borrada



(c) Original

Figure 3: Onde eu queria estar agora.



(a) Desborrada



(b) Borrada



(c) Original

Figure 4: Bola de vidro nos ensina sobre o fenômeno da refração.

## 4.2 Deconvolução Cega

Para realizar a deconvolução cega, utilizamos seguinte algoritmo:

Abaixo se encontram imagens comparando os nossos resultados com os resultados obtidos pelos autores do artigo original [SJA08]:

---

**Algorithm 3** Blind Deconvolution

---

**Require:** The blurred image  $I$  and a kernel estimate

Compute smooth region  $\Omega$  with  $t = 5$ .

$L \leftarrow I$

$i \leftarrow 0$

**while**  $i < 30$  **do**

    Update  $\Psi$  according to (7)

    Compute  $L$  according to (10)

    Update  $f$  according to (12)

$i \leftarrow i + 1$

**end while**

Choose the best looking image

---



(a) Imagem Borrada




(b) Nosso resultado




(c) [SJA08]


Figure 5: Comparação das imagens



(a) Kernel Inicial



(b) Nosso Kernel Final



(c) [SJA08]

Figure 6: Comparação dos kernels

O resultado de cada iteração para a obtenção da imagem da Figura 5 e do Kernel da Figura 6, podem ser observados nas Figuras 7 e 8.



(a) Iteração 0



(b) Iteração 1




(c) Iteração 4




(d) Iteração 8 (Imagem Final)


Figure 7: Resultado por iteração da imagem




(a) Iteração 0



(b) Iteração 1




(c) Iteração 4



(d) Iteração 8 (Kernel Final)

Figure 8: Resultado por iteração do kernel





(a) Imagem Borrada



(b) Nosso resultado



(c) [SJA08]



(d) Imagem Borrada




(e) Nosso resultado




(f) [SJA08]



(g) Imagem Borrada



(h) Nosso resultado



(i) [SJA08]

## 5 Conclusão

Deconvolução cega é um difícil. Ao longo deste trabalho, exploramos os desafios e as soluções propostas para o problema de desborramento de imagens a partir de uma única imagem. A partir da formulação de um modelo probabilístico que unifica os aspectos de deconvolução cega e não cega, implementamos um método que combina diversas técnicas para estimar tanto a imagem latente quanto o kernel de borramento.

No entanto, nossa implementação enfrentou dificuldades significativas na convergência dos métodos de otimização, particularmente na estimativa da imagem latente  $L$  e do kernel de borramento  $f$ , já que para este último, resolvemos utilizando mínimos quadráticos e não o método de ponto interior, como originalmente proposto pelos autores do artigo. Dessa forma, consideramos que os resultados obtidos não foram satisfatórios como esperávamos, devido a problemas de convergência e estabilidade numérica.

Dito isso, acreditamos que a realização do trabalho foi uma experiência bem construtiva para ambos os integrantes do grupo.



## 6 Sugestões

Inspirado na última aula dessa cadeira, propomos treinar uma rede neural para gerar estimativas do kernel de borrimento a partir da imagem observada. O cálculo de  $f$  é provavelmente a etapa mais computacionalmente intensiva do algoritmo. Com uma estimativa inicial melhor de kernel, o algoritmo convergiria mais rapidamente, necessitando fazer esse cálculo menos vezes. Além disso, poderíamos adicionar um tratamento de bordas (que não realizamos) para reduzir o ruído periódico da imagem.

## Referências

- [Ara+20] Alexandre Araujo et al. “On Lipschitz Regularization of Convolutional Layers using Toeplitz Matrix Theory”. In: *AAAI Conference on Artificial Intelligence*. 2020. URL: <https://api.semanticscholar.org/CorpusID:226281883>.
- [Bra99] Ronald Bracewell. *The Fourier Transform And Its Applications*. McGraw-Hill, 1999.
- [KKB07] Kwangmoo Koh, Seung-Jean Kim, and Stephen Boyd. “An Efficient Method for Large-Scale l1-Regularized Convex Loss Minimization”. In: Jan. 2007, pp. 223–230. ISBN: 978-0-615-15314-8. DOI: 10.1109/ITA.2007.4357584.
- [RB05] S. Roth and M.J. Black. “Fields of Experts: a framework for learning image priors”. In: *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR’05)*. Vol. 2. 2005, 860–867 vol. 2. DOI: 10.1109/CVPR.2005.160.
- [Sim02] Marvin Simon. “Probability Distributions Involving Gaussian Random Variables, A Handbook for Engineers and Scientists”. In: (2002). DOI: 10.1007/978-0-387-47694-0.
- [SJA08] Qi Shan, Jiaya Jia, and Aseem Agarwala. “High-quality Motion Deblurring from a Single Image”. In: *ACM Transactions on Graphics (SIGGRAPH)* (2008).
- [WF07] Yair Weiss and William T. Freeman. “What makes a good model of natural images?” In: *2007 IEEE Conference on Computer Vision and Pattern Recognition*. 2007, pp. 1–8. DOI: 10.1109/CVPR.2007.383092.